



Full35 Activation 預先選擇：為什麼先用 A8？

FP32 weights、無訓練 smoke；比較量化前後的 one-to-one raw 輸出與 Top-300 候選集合

① 原始輸出被量化扭曲多少？



② Top-300 class-anchor 候選保留多少？



資料來源：activation-smoke-v2.json | 每點取Detect／Pose較差值 | selection band是預選判讀，不是正式精度門檻

預選結論

主線 A8：qSiLU、poly_quality、poly_shift
後續研究：qSiLU A6；poly_quality／poly_shift A7
停止新增：SiLU、Hardswish、ReLU

理由：先用A8隔離weight誤差，再降低A-bit。

SD4如何納入

標準主線是 W-SD4（weight codebook）：
每條A8 policy都配 W8／W4／Fixed SD4／LS-SD4。

A-SD4（activation使用SD4 codebook）另列探索支線，
必須先和同為4-bit的LSQ+ A4公平比較。

老師看圖時要注意

NRMSE／TopK overlap是工程proxy，不是mAP。
0.3797不代表準確率下降37.97%。
最後仍以COCO box、BBAT box、BBAT pose
三項mAP下降各自不超過0.04作gate。